



RAPPORT DEFI IA 2024-2025

[UFHB]-@WELFARE

MARIAM DJIRE, ANGELA KONATE, FREDERIC AKADJE

Table des matières

Contexte et problématique.....	2
Description des données.....	3
Métrique d'évaluation	5
Modélisation.....	6
Etiquette	6
Disposition du jeu de données.....	6
Tendance au sein des données	6
Caractéristiques	7
Algorithmes d'apprentissage.....	9
Caractéristiques du modèle obtenu.....	9
Recommandation d'un produit.....	11

Contexte et problématique

L'utilisation de la data et le développement des capacités analytiques sont un axe majeur du plan stratégique du Groupe Carrefour à horizon 2027. L'Analytics Factory de Carrefour France est le pilier de cette transformation analytique, au service des clients et de l'ensemble des équipes métier de Carrefour. Au sein des équipes de data science de l'analytics factory, utilise notamment des approches de machine learning et de recherche opérationnelle pour résoudre des défis commerciaux et opérationnels comme les ruptures en magasin, la prévision des ventes promotionnelles, l'optimisation de l'assortiment des produits et les recommandations personnalisées sur le site carrefour.fr.

L'objectif de ce défi est de prédire le réachat d'un produit par un client sur la plateforme e-commerce. Une des originalités de cette problématique est que les courses alimentaires bénéficient souvent d'une plus grande fréquence d'achat, par rapport à d'autres produits non alimentaires. En outre, cette fréquence peut varier beaucoup entre les produits (par ex entre un pack de yaourt et un moulin à poivre) ainsi que d'un client à un autre.

Ces prédictions sont cruciales à plusieurs titres :

- Amélioration de la satisfaction client : en recommandant des produits pertinents aux clients, les entreprises améliorent leur expérience d'achat globale, notamment en l'accéléralant ou la fluidifiant. Cela participe à la fidélisation des clients.
- Amélioration des ventes : en recommandant des produits pertinents que les clients sont susceptibles de racheter, les entreprises peuvent augmenter leurs ventes et leurs revenus.

Description des données

1-Base de données « Transactions »

Base de données d'apprentissage sur l'historique des transactions d'achat de 100000 clients sur 2 années (en 2022 et 2023).

Date	Transaction	Customer_id	Product_id	quantity	...	Is_promo
01/01/2022	Transaction_1	Household 1	Product_1			
...	...	...	...	...	...	...
01/12/2023	Transaction_p	Household 100000	Product_y			

Il comporte 10 colonnes :

- **date** : Date de la transaction
- **transaction_id** : Identifiant de la transaction
- **customer_id** : Identifiant du client
- **product_id** : Produit acheté
- **has_loyalty_card** : Indicateur indiquant si le client possède une carte de fidélité
- **store_id** : Magasin où l'achat a été effectué
- **is_promo** : Indicateur indiquant s'il y avait une réduction sur le produit
- **quantity** : Quantité achetée du produit
- **format** : Format de l'activité de commerce électronique (clcv, lex ou DRIVE)
 - clcv : courses livrées chez vous
 - lex : livraison express
 - DRIVE.
- **orderChannelCode** : Indique si l'activité en ligne a été effectuée via le site web ou l'application mobile

2- Base de données « Products »

Ce jeu de données contient des informations détaillées sur les produits.

Product_id	Product_description	Class_key	...	Carrefour_brand
Product_1	PET 1L LORINA TONIC ARTISANAL	Department_10	...	0
...	...	...	...	...
Product_y	CHARGE BUT 6K AZ	Department_66	..	0

Il comporte 49 colonnes dont 10 d'entre elles seront présenté ici :

- **product_id** : Nom du produit
- **product_description** : Description du produit
- **department_key** : Clé du département
- **class_key** : Clé de la classe

- ***subclass_key*** : Clé de la sous-classe
- ***sector*** : Nom du secteur
- ***brand_key*** : Nom de la marque
- ***shelf_level1*** : Catégorie de rayon de premier niveau
- ***shelf_level2*** : Catégorie de rayon de deuxième niveau
- ***shelf_level3*** : Catégorie de rayon de troisième niveau
- ***shelf_level4*** : Catégorie de rayon de quatrième niveau
- ***sector*** : Secteur

3- Base de données « Test »

Ce jeu de données contient les achats réels des 80 000 premiers clients en 2024. Ce sont les 10 premières transactions de chaque client.

Transaction	Customer_id	Product_id
Transaction_1	Household 1	Product_97xx
...	...	
Transaction_p	Household 80000	Product_21xx

Il comporte trois colonnes :

- ***transaction_id*** : Identifiant de la transaction
- ***customer_id*** : Identifiant du client
- ***product_id*** : Identifiant du produit acheté

Les transactions de 20000 clients en 2024 sont masquées et elles représentent les clients pour lesquels nous prédiront la première transaction. Notre tâche consistera à créer un modèle qui, compte tenu de l'historique des transactions et des informations sur les produits, recommande les 10 meilleurs produits pour chacun de ces 20000 clients. Ces recommandations doivent représenter les produits dont vous pensez qu'ils sont les plus susceptibles d'être achetés en premier.

Métrique d'évaluation

Les performances de votre modèle seront évaluées à l'aide de la métrique Hit Rate@10. Cette mesure calcule le pourcentage de produits recommandés qui sont réellement achetés par le client lors de sa première transaction en 2024. En d'autres termes, sur les 10 produits recommandés, combien sont réellement achetés par le client.

La formule du HitRateK est donnée par :

$$HitRate@K(a, y) = \frac{1}{\min(N, 10)} \sum_{i=1}^{10} 1_{y_i \in \{a_1, \dots, a_N\}}$$

- La division par $\min(N, 10)$ afin d'obtenir un score parfait de 1 lorsque le client achète moins de 10 produits et que tous ces produits sont prédits.
- Cette définition suppose implicitement que tous les $\{y_1, \dots, y_{10}\}$ sont distincts. Si certaines valeurs sont identiques, le résultat peut être faussé : par exemple, si le même produit est saisi 10 fois et que ce produit est effectivement acheté, alors le score est 1. Pour éviter un tel cas, il est demandé de prédire 10 produits différents.

Modélisation

Nous nous ramenons à un problème d'apprentissage supervisé afin d'utiliser des algorithmes de Machine Learning.

Etiquette

La colonne cible créée indique 1 si le produit y figure dans le premier panier (base test) du client x et 0 sinon.

Disposition du jeu de données

Un résumé des transactions est créé à l'aide des 3 tables « transaction », « product », « test » de la façon suivante :

Customer id	Product id	Caract 1	Caract 2	...	Caract m-1	Target
Household 1	Product 1					0
Household 1	Product 2					1
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
Household n	Product n			...		0

Caract : Caractéristique

Pour chaque transaction (client-produit) diverses caractéristiques (variables) sont créées afin de synthétiser au mieux l'entièreté des transactions effectuées sur le produit x par le client y.


La structure présentée permet de ramener chaque transaction réalisée par un client sur produit donné à une seule ligne résumant l'ensemble des transactions effectuées. Les produits conservés pour un client donné sont essentiellement les produits achetés au moins une fois par le client selon l'historique fourni.

Diverses caractéristiques seront donc créées afin d'enrichir le modèle lui permettant de capturer les relations complexes au sein du jeu de données.


Tendance au sein des données

La configuration proposée présente un déséquilibre au niveau des modalités de la colonne cible "ispurchase". 5% de 1 (rachat) contre 95% 0 (Non-rachat). Quelques représentations permettent alors d'analyser les tendances d'achats au sein des données.

Figure 1: Tendances d'achats par année selon les trimestres et mois



Les taux de rachat varient significativement selon les mois et les trimestres. Les pics aux trimestres 4 et le mois 12 (fin d'année) indiquent une saisonnalité marquée, sur les derniers périodes de l'années.



Certains produits (ex : ID 23971, 57942) et catégories comme l'eau, les crèmes, les produits laitiers, fruits, légumes, charcuteries, Boissons, Hygiène et Beauté, affichent des volumes de rachat élevés traduisant une fidélité client ou une consommation régulière. Ces tendances induisent l'ajout de certaines caractéristiques au jeu de données dans le but de mieux capturer ces tendances.

Caractéristiques

4 principales caractéristiques sont créées :

- Les caractéristiques liées au client ;
- Les caractéristiques liées au produit ;
- Les caractéristiques liées à l'interaction client-produit ;
- Les caractéristiques liées à l'interaction client-produit-période ;

Type de caractéristique	Caractéristiques
Liées au client	'transaction_count_cust', 'total_quantity_cust', 'loyalty_card_usage', 'promo_ratio'
Liées au produit	'Product popularity', 'promo_ratio_onProd', 'avg_quantity_onProd', 'is_dominant_shelf_level1', 'product_description_frequency', 'department_key_frequency', 'class_key_frequency', 'subclass_key_frequency', 'sector_frequency', 'brand_key_frequency', 'shelf_level1_frequency', 'shelf_level2_frequency', 'shelf_level3_frequency', 'shelf_level4_frequency'
Liées à l'interaction client-produit	'interaction_count_onProdCust', 'total_quantity_onProdCust', 'avg_quantity_onProdCust', 'unique_products_cust', 'promo_ratio_onProdCust', 'last_quantity', 'total_transactions_onDominant', 'total_quantity_onDominant', 'proportion_transaction_onDominant', 'ANNULEE', 'EN COURS DE PREPARATION', 'EXPEDIEE', 'LIVREE',

	'MOBILE_APP', 'NON LIVREE', 'PREPAREE', 'PRISE EN COMPTE', 'WEBSITE','CLCV','DRIVE', 'LEX',
Client -produit– période	'days_between_purchases_onProdCust', 'days_since_last_purchase_onProdCust', 'is_first_transaction_category_2022', 'is_first_transaction_category_2023', 'favorite_month', 'favorite_quarter', 'total_transactions_last_three_mounth', 'total_quantity_last_three_mounth', 'is_first_transaction_product_2022', 'is_first transaction product 2023'

La description des différentes caractéristiques ainsi que leurs méthodes de calcul sont clairement indiquées dans les fichiers notebook transmis.

Algorithmes d'apprentissage

Sur la structure des données présentées plus haut, sont appliquées différentes méthodes d'apprentissages supervisés basiques (non optimisées) sur un échantillon de 60000 clients. Les résultats sont confinés dans le tableau ci-dessus.

Model	auc-train	auc-test	Accuracy	F1-score	Précision	Recall	HitRate	Time(s)
CatBoostClassifier	0,8518	0,8472	0,9554	0,1385	0,5856	0,0785	0,4030	10630
XBGClassifier	0,8480	0,8449	0,9555	0,1277	0,5956	0,0715	0,3885	3452
LGBMClassifier	0,8426	0,8411	0,9554	0,1170	0,5991	0,0648	0,3834	3856
LogisticRegression	0,8199	0,8189	0,9549	0,1100	0,5477	0,0611	0,3537	4209

auc-train : métrique 'roc-auc' calculée sur l'échantillon d'entraînement ;

auc-test : métrique 'roc-auc' calculée sur l'échantillon test ;

HitRate : hitRate10 calculé sur l'entièrete du jeu de données (60000 clients) selon les modèles obtenus ;

Time : temps d'exécution de l'algorithme complet


Par suite, le modèle *LightGBM* sera choisi en tenant compte des valeurs (*auc-test*, *time*) et des soumissions réalisées.

L'algorithme d'apprentissage final comporte l'ensemble des transformations réalisées afin d'obtenir la structure présentée plus haut, ainsi que le modèle *lighGBM* entraîné sur un échantillon de 60000 clients (ressource computationnelle limitée). Les paramètres passés au modèle sont obtenus par *cvGridSearch* sur un échantillon de 4000 clients.

Caractéristiques du modèle obtenu

Modèle met en avant certaines caractéristiques dans la discrimination d'un achat ou non. La pertinence sera évaluée ici selon l'importance *gain*¹. Un top 10 des variables les plus pertinentes pour le modèle est proposé.

¹ Mesure la réduction d'entropie lorsque la feature est utilisée pour une séparation.



- **days_since_last_purchase_onProdCust:** Nombre de jours écoulés depuis le dernier achat du produit par le client référencé à **05/01/2024** comme date du premier achat,
- **interaction_count_onProdCust:** Nombre total de transactions réalisées par un client sur produit donné,
- **transaction_count_cust:** Nombre total de transactions réalisées par le client,
- **days_between_purchases_onProdCust:** Durée moyenne entre deux achats du même produit par le client,
- **total_quantity_last_three_mounth:** Quantité totale achetée par le client durant les 3 derniers mois,
- **Total_quantity_cust :** Quantité totale de produits achetés par le client.
- **unique_products_cust:** Nombre de produits distincts achetés par le client,
- **total_transactions_last_three_mounth:** Nombre de transactions réalisées par le client durant les 3 derniers mois,
- **product_popularity:** Nombre total de clients ayant acheté le produit,
- **total_quantity_onProdCust:** Quantité totale du produit achetée par le client,

Le modèle identifie la récence, l'engagement, et la performance du produit comme leviers principaux pour prédire et stimuler les comportements clients.

Recommandation d'un produit

L'algorithme d'apprentissage est utilisé afin de prédire les probabilités de réachats. La structure suivante est par suite obtenue et utilisée pour le calcul du HitRate10.

Customer_id	Product_id	Proba
Household_1	Product_1	p_1
Household_1	Product_2	p_2
.	.	
.	.	
.	.	
Household_n	Product_n	p_n

p_i : probabilité de rachat à la première transaction

Sur ce dataset sera ensuite utilisé la fonction '*rank*', puis '*head(10)*' afin de garder pour chaque client les 10 produits les plus susceptibles d'être rachetés à la première transaction.

Résultat meilleur soumission : 0,38544

Rang : 2ème